

تقریباً ۲۵٪ - یادگیری ماشین برای پیروان و علاقه‌مندان

مردی کافه ۹۹۱۰۷۵۳

①

الف - ۱.۱

$$P(C_1) = \pi, \quad P(C_2) = 1 - \pi$$

$$P(x|C_1) = N(\mu_1, \Sigma_1), \quad P(x|C_2) = N(\mu_2, \Sigma_2)$$

$$\text{Decision Boundary} \Rightarrow P(C_1|x) = P(C_2|x) \Rightarrow \frac{P(x|C_1)P(C_1)}{P(x)} = \frac{P(x|C_2)P(C_2)}{P(x)}$$

$$\Rightarrow P(x|C_1)P(C_1) = P(x|C_2)P(C_2)$$

$$\Rightarrow \ln[P(x|C_1)P(C_1)] = \ln[P(x|C_2)P(C_2)] = \ln P(x|C_1) + \ln P(C_1) = \ln P(x|C_2) + \ln P(C_2)$$

$$\Rightarrow -\frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_1| - \frac{1}{2} (x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) + \ln \pi$$

$$= -\frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_2| - \frac{1}{2} (x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) + \ln(1 - \pi)$$

$$\Rightarrow \ln |\Sigma_1| + (x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) - 2 \ln(\pi) = \ln |\Sigma_2| + (x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) - 2 \ln(1 - \pi)$$

$$\Rightarrow \ln |\Sigma_1| + x^T \Sigma_1^{-1} x + \mu_1^T \Sigma_1^{-1} \mu_1 - 2 \mu_1^T \Sigma_1^{-1} x - 2 \ln(\pi)$$

$$= \ln |\Sigma_2| + x^T \Sigma_2^{-1} x + \mu_2^T \Sigma_2^{-1} \mu_2 - 2 \mu_2^T \Sigma_2^{-1} x - 2 \ln(1 - \pi)$$

۱.۱ - ب)  $\Sigma_1 = \Sigma_2 = \Sigma$


$$\Rightarrow \ln |\Sigma| + x^T \Sigma^{-1} x + \mu_1^T \Sigma^{-1} \mu_1 - 2 \mu_1^T \Sigma^{-1} x - 2 \ln(\pi)$$

$$= \ln |\Sigma| + x^T \Sigma^{-1} x + \mu_2^T \Sigma^{-1} \mu_2 - 2 \mu_2^T \Sigma^{-1} x - 2 \ln(1 - \pi)$$

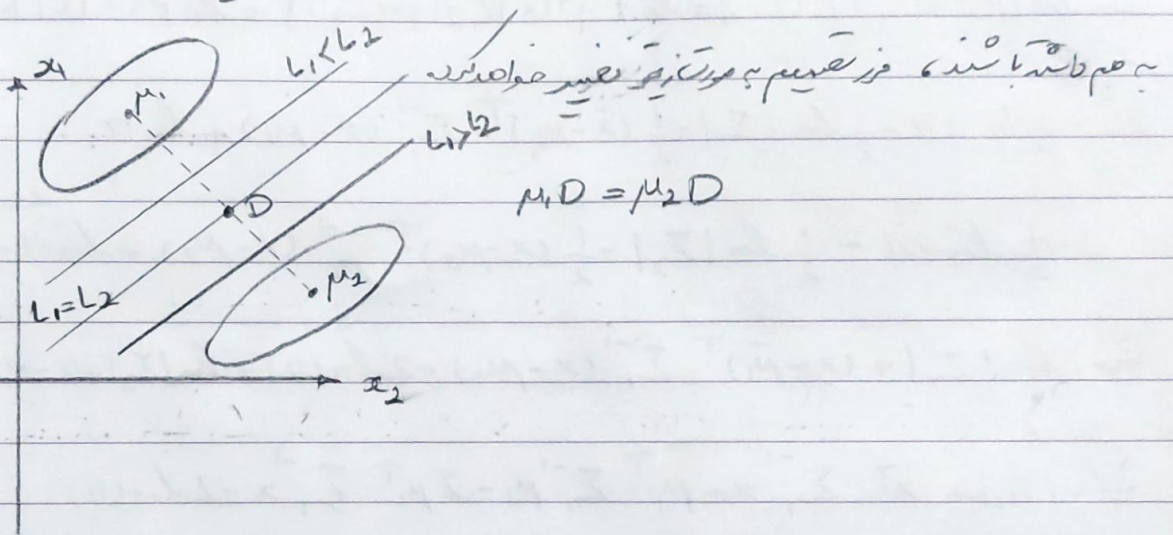
$$\Rightarrow \underbrace{[-2(\mu_1^T - \mu_2^T) \Sigma^{-1}] x}_A + \underbrace{\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2 - 2 \ln(\pi) + 2 \ln(1 - \pi)}_B = 0$$

\* فرم صورت ابرمفهو در آمد.

ج ۱ اگر دو توزیع دارای پارامترهای یکسان باشند به خط آن ها به صورت زیر خواهد بود:



حال اگر پارامترهای misclassification بخاریم هزینه ای برابر با  $\lambda$  و خط بکسیم به ازای  $\lambda$  در حالتی که  $\lambda$  و  $\lambda_2$  می تواند نسبت



اگر خطای misclassification پارامتری دو کلاس برابر باشد تا بقوت هزینه بندی دقیقاً بین دو توزیع می افتد زیرا که  
به ازای خطای دسته بندی دو کلاس به یک میزان جریمه می شود.

اگر  $\lambda_1$  باشد به این معنی است که اگر داده کلاس اول به کلاس دوم نسبت داده شود خطای هزینه بندی مرکب شود

بنابراین باید سعی کنیم این خطا کمتر رخ بدهد پس باید هزینه ای توزیع با میانگین  $\mu_2$  نزدیک کنیم که کمتر به اندازه

اما جریمه می شود.



اگر  $L_1 < L_2$  باشد ما استدلالی شبیه به قبل باید فرماییم توزیع با میانگین  $\mu_1$  نزدیکتر است.

در حالت 2 یا در صورتی که دقیقاً بین توزیع ها قرارند احتمال  $\pi$  برابر با 0.5 باشد و در حالت کلی

اگر  $L_1 < L_2$  باشد  $(1-\pi) \times L_2$  کمتر از  $\pi \times L_1$  باشد، در این صورت  $C_1$  اختصاص می یابد زیرا که احتمال

صفای احتمال برای خروجی  $C_1$  کمتر از  $C_2$  است.

$$\frac{P(X|C_1)P(C_1)}{N(\mu_1, \Sigma)} \quad ? \quad \frac{P(X|C_2)P(C_2)}{N(\mu_2, \Sigma)}$$

$$X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (3)$$

$$\frac{1}{\sqrt{(2\pi)^2 |\Sigma|}} \exp\left(-\frac{(X-\mu_1)^T \Sigma^{-1} (X-\mu_1)}{2}\right) \pi \quad ? \quad \frac{1}{\sqrt{(2\pi)^2 |\Sigma|}} \exp\left(-\frac{(X-\mu_2)^T \Sigma^{-1} (X-\mu_2)}{2}\right) (1-\pi)$$

$$\exp\left(-\frac{(X-\mu_1)^T \Sigma^{-1} (X-\mu_1)}{2}\right) \pi \quad ? \quad \exp\left(-\frac{(X-\mu_2)^T \Sigma^{-1} (X-\mu_2)}{2}\right) (1-\pi)$$

$$\exp\left(-\frac{\sigma^2 (X-\mu_1)^T (X-\mu_1)}{2}\right) \pi \quad ? \quad \exp\left(-\frac{\sigma^2 (X-\mu_2)^T (X-\mu_2)}{2}\right) (1-\pi)$$

$$\exp\left(-\frac{\sigma^2 [\text{distance between } X \text{ and } \mu_1]^2}{2}\right) \pi \quad ? \quad \exp\left(-\frac{\sigma^2 [\text{dist between } X \text{ and } \mu_2]^2}{2}\right) (1-\pi)$$

if  $\pi = 0.5$  and  $\text{dist}(X, \mu_1) < \text{dist}(X, \mu_2) \Rightarrow P(C_1|X) > P(C_2|X)$

$$D = \{(x^i, y^i)\}_{i=1}^N \quad y = \{0, 1\}$$

(2)

if  $C=1 \Rightarrow y=1$  and if  $C=2 \Rightarrow y=0$

$$N_1 = \sum_{i=1}^N y^i \Rightarrow R = \frac{N_1}{N}$$

$$X = \begin{bmatrix} x_1^1 & x_2^1 & \dots & x_N^1 \\ x_1^2 & x_2^2 & \dots & x_N^2 \end{bmatrix}$$

dimension  $d=2$

$$\log \text{likelihood} = \mathcal{L}(\mu, \Sigma | X) = \ln \prod_{i=1}^N \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp\left(-\frac{(x^i - \mu)^T \Sigma^{-1} (x^i - \mu)}{2}\right)$$

$$= \ln \prod_{i=1}^N \frac{1}{\sqrt{(2\pi)^2 |\Sigma|}} \exp\left(-\frac{(x^i - \mu)^T \Sigma^{-1} (x^i - \mu)}{2}\right)$$

$$= \sum_{i=1}^N \left(-\ln(2\pi) - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} (x^i - \mu)^T \Sigma^{-1} (x^i - \mu)\right)$$

$$= -N \ln(2\pi) - \frac{N}{2} \ln |\Sigma| - \frac{1}{2} \sum_{i=1}^N (x^i - \mu)^T \Sigma^{-1} (x^i - \mu) = \mathcal{L}(\mu, \Sigma | x^i)$$

$$\mu: \quad \frac{\partial \mathcal{L}(\mu, \Sigma | x^i)}{\partial \mu} = +\frac{1}{2} \sum_{i=1}^N \Sigma^{-1} (\mu - x^i) \Rightarrow \sum_{i=1}^N \Sigma^{-1} (\mu - x^i) = 0$$

$$\Rightarrow 0 = N\mu - \sum_{i=1}^N x^i \Rightarrow \hat{\mu} = \frac{\sum_{i=1}^N x^i}{N}$$

$$\mu_1 = \frac{\sum_{i=1}^N y^i x^i}{N_1}, \quad \mu_2 = \frac{\sum_{i=1}^N (1-y^i) x^i}{N_2} \quad (N_2 = N - N_1)$$



$$L(\mu, \Sigma | x^i) = -N \ln(2\pi) - \frac{N}{2} \ln |\Sigma| - \frac{1}{2} \sum_{i=1}^N (x^i - \mu)^T \Sigma^{-1} (x^i - \mu)$$

$$= -N \ln(2\pi) + \frac{N}{2} \ln |\Sigma^{-1}| - \frac{1}{2} \sum_{i=1}^N \text{tr} [\Sigma^{-1} (x^i - \mu)(x^i - \mu)^T]$$

$$\frac{\partial L(\mu, \Sigma | x^i)}{\partial \Sigma^{-1}} = \frac{N}{2} \Sigma^T - \frac{1}{2} \sum_{i=1}^N ((x^i - \mu)(x^i - \mu)^T)^T$$

$$= \frac{N}{2} \Sigma - \frac{1}{2} \sum_{i=1}^N (x^i - \mu)(x^i - \mu)^T \Rightarrow \frac{\partial L(\mu, \Sigma | x^i)}{\partial \Sigma^{-1}} = 0$$

$$\Rightarrow 0 = N \Sigma - \sum_{i=1}^N (x^i - \hat{\mu})(x^i - \hat{\mu})^T \Rightarrow \Sigma = \frac{\sum_{i=1}^N (x^i - \hat{\mu})(x^i - \hat{\mu})^T}{N}$$

\* قسمت الف، محاسبه ای که برای فرآیند تقسیم به دست می آید یک محاسبه دوم بر حسب  $\Sigma$  است و باعث می شود

یک Decision Boundary از فرجه ۲ داشته باشیم ولی اگر مانند قسمت ب، ماتریس های کواریانس یکسان شوند

بخش دوم محاسبه نمی شود و فرآیند تقسیم به صورت خطی و یک ابر صفحه خواهد آمد.

(۲-۱)

الف) در حالت گسسته فرض استقلال شرطی برقرار نیست زیرا که با داشتن مقدار  $x_2$  در احتمال ویرس  $x_1$  تحت تأثیر


$$P(x_1 | x_2 = 0) \neq P(x_1) \quad \text{قرار می گیرد.}$$

ب) در این حالت کانتور ها به شکل دایره درآمده اند که نشان دهنده ماتریس کواریانس  $\Sigma$  است و

بنابراین ویرس ها دارای استقلال شرطی هستند و برای پیدا کردن فرز با توجه به اینکه که نه کلاس ها داخل دیگر فرآیند

گرفته و کانتورهای با احتمال ۰.۵ مشخص شده اند و فرآیند تقسیم باید در داخل دایره کسره  $\epsilon$  (مضرب)

قرار بگیرد به صورت دایره



ج، در این شکل کانتورها به صورت بیضی‌ها هستند که بر اساس اصل آن‌ها معادلات محورها مختصات نیستند. بنابراین فاصله‌های کم‌ترین نیز به صورت قطری نبوده است و استقلال شرط برقرار نیست.

۱-۳ مدل‌های regression اگر فیچرها را بتوان از روی یکدیگر <sup>۲</sup> صحت آورد حالتی ایجاد می‌شود که به آن

multi collinearity گفته می‌شود و نشان از داشتن correlation بالا بین فیچرها است. این پدیده باعث می‌شود که

مدل logistic regression، ۲ مشکل پیش بیاید، یکی اینکه به طرز فزاینده‌ای مدل بسیار غنی‌تر می‌شود و

باقی‌مقدار کوچک در داده‌ها، وزن‌ها به صورت نامعنان تغییر می‌کنند و مشکل دوم این است که با داشتن فیچرهای

correlated، نمی‌توان اهمیت فیچرها را به صورت مستقیم از بزرگی وزن‌ها (ضرایب) قیاس کرد؛ اما در این

مسئله با توجه به اینکه <sup>۱</sup> گفته شده است مقدار یکی فیچر داریم و آن فیچر خودش تکرار شده است به قدری که تنها مشکل

اول را اینجا ایجاد می‌شود و بزرگی وزن‌ها با تغییرات کوچک فیچرها به صورت نامعنان به مقدار زیادی تغییر می‌کنند و

نایاب‌تر می‌شوند.



الف)

• SVM حاشیه نرم؛ نادرست - در SVM با حاشیه نرم، یادداشت با مقدار کوچک کاره می‌دهد و حاشیه را تحت آن نامیده گرفته شود و حاشیه بزرگتر می‌شود و مقدار بالای C باعث می‌شود که حاشیه بزرگ شود بطوریکه مقدار C برابر با بهترین حالت می‌باشد SVM با حاشیه سخت می‌شود.

• هسته (Kernel) کار می‌کند؛ نادرست - در هسته کار می‌کند هر چه مقدار C بالا می‌رود حاشیه می‌شود که حاشیه کار می‌کند و در واقع به داده‌های آموزش می‌چسبند و باعث overfitting می‌شوند و مقدار بزرگتری برای C باعث حاشیه بزرگتر می‌شود که می‌شود باعث شود که مدل خطی ساده شود و در واقع آموزش می‌دهد و نتیجه این این پارامتر با یک متوسط ثابت می‌ماند cross validation بهینه شود تا قبل از بهترین عملکرد داشته باشد.

ب)

۱A. Linear - برای صفی ایجاد شده مشخصاً یک خط است.

۱B.  $RBF, \sigma = 2$  - در اکثر این ایجاد شده و در اکثر یک SVM با کرنل گاوسی است و با مقایسه با سایر کرنل های

گاوسی، این دیگر کارایی بیشتری دارد بنابراین که آن از همه بزرگتر است.

۱C. Second Order Polynomial - از ایجاد شده صورت یک چند جمله ای درجه دوم است.

۱D.  $RBF, \sigma = 0.08$  - دیگران نشان دهنده پیچیده ترین مدل است و به طره ها بسیار گسترده است بنابراین

معمولاً برای یک کرنل گاوسی با کمترین پارامتر است.

۱E.  $RBF, \sigma = 0.5$  - دیگران نشان دهنده کرنل گاوسی است که به مقایسه با ۲ دیگر کرنل های دیگر مشخص

می شود که برای ۱۵۱ بین پارامتر و عملکرد دیگر است.



④ برای اینکه اثبات کنیم یک کنترل valid است کافی است که آن را به صورت یک ضد ظاهر بنویسیم و برای

اثبات valid بودن این کنترل که بر روی رشته اعمال می شود به صورت زیر عمل می کنیم:

۱) ابتدا یک فانتیس  $\Phi$  به صورت زیر برای دو رشته فرض کرد و میسازیم بطوریکه هر یک فانتیس های زیر رشته  
است و ستون های فانتیس، اما زیر رشته های خود رشته هستند و زیر رشته ده رشته موجود باشد و باید این کار را

اگر نباشد باید مغفول می کنیم.  
 $\Sigma = \{a, u, e\}$      $S_1 = aue$      $S_2 = auue$   
 $\{a, u, e, au, ue\} = A \Rightarrow |A| = 5$

$\Phi =$	a	u	e	au	ue	uu	auu	uue	aue	auue
aue	1	1	1	1	1	0	0	0	1	0
auue	1	1	1	1	1	1	1	1	0	1

حال برای داشتن خروجی تعداد زیر رشته های مشترک کافی است که فانتیس  $\Phi$  را در  $\Phi^T$  ضرب کنیم که در این صورت

باید  $K(S_1, S_2)$  و  $K(S_1, S_2)$  را فانتیس حاصل برابر می خواهند که همان تعداد رشته های مشترک و یا خروجی

کنترل مورد نظر است بنابراین نشان طعم که کنترل را می توان به صورت ضد ظاهر نوشت بنابراین این کنترل یک کنترل

valid است. (می توانیم به جای ضد کل فانتیس  $\Phi$ ، فقط سطر اول را در سطر دوم ضد ظاهر کنیم و

خروجی باز هم همان عدد 5 خواهد بود.)