

توانی در یادگیری ماشین برای سوانح و فایده

مردی کافر ۹۹۲۱۰۷۵۳

نیلوفر

①

الف) در ساده ترین حالت، محاسبه کانولوشن دو تصویر هر یک با ابعاد $N \times N$ ، هزینه زمانی $O(N^2 \times N^2)$ برابر با $O(N^4)$ خواهد داشت.

ب) اگر بخواهیم دو چند جمله ای را در یک ضرب کنیم می توانیم آنرا به ضرب های از چند جمله ای ها را برداری کنیم و به هم ضرب کنیم تا نتیجه محاسبه شود. این کار کانولوشن گفته می شود. روش دیگر این است که برای این محاسبه ابتدا چند جمله ای ها را به فضای دیگری تبدیل کنیم و سپس ضرب را به صورت $dementaise$ بین درایه های هر لیست انجام دهیم که این فضای فضایی فوریه است که می توان به صورت دیگر نشان داد: $FFT(g) \cdot FFT(f)$ ؛ سپس به طریقی که این حاصل را به فضای اولیه برگردانیم که با عکس تبدیل فوریه امکان پذیر است. بنابراین برای ضرب چند جمله ای f و چند جمله ای g می توانیم از روش روبرو استفاده کنیم $FFT^{-1}(FFT(f) \cdot FFT(g))$. این روش هزینه زمانی $O(n \log n)$ دارد که در ابتدا چند جمله ای باید به بالاتر، به n داشته باشد. حال می توانیم از این روش برای کانولوشن در فضای دو بعدی استفاده کنیم. برای این منظور به لیفورت محل می بینیم که دو ماتریس را از حالت دو بعدی به عملیات $flatten$ به آرایه های یک بعدی تبدیل می کنیم و در فضای یک بعدی کانولوشن را انجام می دهیم و نتیجه را به حالت دو بعدی برگردانیم. در ابتدا باید هر دو ماتریس را با صفر $padding$ کنیم تا مقادیر کمتری در ریف مناسب در تصویر قرار بگیرند. بنابراین اگر $H \times W$ باشد کانولانت

اگر تصویر و کرنل را به اندازه مستقیم به هم Convolution، یعنی $N+K-1$ ، padding کنیم، هر دو را

flatten کنیم، با FFT، کانونالها را ابتدا به هم وصل کنیم و حالت دو بعدی بگیریم. اگر کرنل $K \times K$ باشد، K

یک عدد فرد باشد، مقدار وسط این کرنل به دو تصویر تقسیم می‌شود و تصویر با ابعاد تصویر اولیه می‌ماند. می‌توانیم این کار را

با cut of kernel کنیم. $\frac{K-1}{2}$ ، نصف دوستانه اول و آخر اینها را هم می‌گیریم. ابعاد خواهد بود $N = N + K - 1 - 2 \left(\frac{K-1}{2} \right)$

تبدیل می‌شود. زمان اجرای این الگوریتم $O(MN \log MN) = O(MN (\log N + \log M))$ خواهد بود. حال در این

اگر دو تصویر هر دو $N \times N$ هستند بنابراین زمان الگوریتم $O(N^2 \log N)$ خواهد بود در حالتی شبیه به این که ابعاد کرنل

بزرگ است این روش به ما کمک می‌کند.

۲.۵ اگر $d > n$ باشد، به ندرت پاسخ برای صف کردن تابع هزینه وجود دارد.

اگر ابعاد دنبال کننده صف کردن هزینه با regularization term داشته باشیم خواهیم داشت:

$$\min J(w) + \lambda \|w\|_2^2 = \min \frac{1}{2} \|Xw - Y\|_2^2 + \lambda \|w\|_2^2$$

اگر λ صفر باشد، به ندرت جواب خواهیم داشت و اگر بزرگتر از صفر باشد، minimizer یکتا خواهیم داشت. این دانش را به عنوان

prior اضافه کنیم و خواص پاسخ با کمترین نرم را به دست آورده ایم زیرا ما داریم پاسخ با نرم کمتر را می‌خواهیم.

فضای حل مساله است. حال می‌توانیم به این صورت زیر بنویسیم:

$$w = X^T \beta + v$$

$$\text{s.t. } v^T x_i = 0 \text{ for all } i$$

$$\Rightarrow \min_{\beta, v} \frac{1}{2} \sum_{i=1}^n \text{loss}(\beta^T x_i, y_i) + \lambda \|X^T \beta\|_2^2 + \lambda \|v\|_2^2$$

اگر به حسب v ، کمینه سازی انجام دهیم تنها پاسخ برپایان $v=0$ است. نتیجه پاسخ با بصورت زیر در می‌آید:

$$w = X^T \beta$$

نشان دهه شد که پاسخ ما، در ابعاد عدد داده ورودی است و کوچکتر یا مساوی n است. به این نتیجه می‌رسیم،

representer theorem گفته می‌شود.

ج ۱. می‌توانیم این مسئله را بصورت زیر بنویسیم:

$$\min_w \|w\|_2^2 \quad \text{subject to } y = Xw$$

* می‌توانیم مسئله را بصورت یک مسئله بدون محدودیت بنویسیم با استفاده از روش لاگرانژ همانند

و دلیل ایند را به سمت مرتب‌سازی می‌دهیم آن است که می‌خواهیم خطا (error) صفر شود.

$$\min_w (\|w\|_2^2 + \lambda \|y - Xw\|_2^2)$$

این یک مسئله Convex است بنابراین گرانت آن صفر خواهد شد و حاصل می‌گردد:

$$2w - 2\lambda X^T(y - Xw) = 0 \Rightarrow w(I + \lambda X^T X) = \lambda X^T y$$

$$\xrightarrow{\lambda \rightarrow \infty} w^* = (X^T X)^{-1} X^T y \xrightarrow{w = X^T \alpha} w^* = (X^T X)^{-1} X^T X X^T \alpha = X^T \alpha = w$$

* نشان داده شد که اگر $w = X^T \alpha$ باشد، گزیده نرم آلفا می‌سازد $y = Xw$ باشد همان $w^* = X^T \alpha$ است و به سبب

SGD به دست آمده است.

۳

اگر فرض کنیم که شبکه ای با ۲ لایه مخفی و ۱ لایه خروجی داریم. در این صورت می توانیم linear regression را برای هر یک از اتصالات به کار ببریم.

فرض کنید به طور مثال در ورودی ۱ داریم که شبکه ای با یک لایه مخفی و یک لایه خروجی به یک شبکه دو لایه مخفی تبدیل کردیم.

اگر فرض کنیم که شبکه ای با ۲ لایه مخفی و ۱ لایه خروجی داریم. در این صورت می توانیم linear regression را برای هر یک از اتصالات به کار ببریم.

$$\left. \begin{aligned} f^1 &= mx + n \\ f^2 &= px + q \end{aligned} \right\} \text{activation functions}$$

$$a^1 = f^1(z^1) = f^1(w^1 x^1 + b^1) = m[w^1 x^1 + b^1] + n = m w^1 x^1 + m b^1 + n$$

$$a^2 = f^2(z^2) = f^2(w^2 a^1 + b^2) = f^2(w^2 (m w^1 x^1 + m b^1 + n) + b^2)$$

$$= f^2(w^2 m w^1 x^1 + m b^1 w^2 + w^2 n + b^2) = p[w^2 m w^1 x^1 + m b^1 w^2 + w^2 n + b^2] + q$$




$$= p w^2 m w^1 x^1 + p m b^1 w^2 + p w^2 n + p b^2 + q = W x^1 + B$$

$\underbrace{\hspace{10em}}_W$


$\underbrace{\hspace{10em}}_B$

در این مدل با تغییرات در ورودی و خروجی می توانیم به نتایج مختلفی دست پیدا کنیم.

الف) با استفاده از شبکه perceptron یک خروجی می‌توانیم AND، OR و NOT را مانند زیر بسازیم و سپس با داشتن این شبکه‌ها می‌توانیم هر رابطه منطقی را به کمک SOP ساخته و با شبکه‌ای بزرگ‌تر به کمک این شبکه‌ها رابطه را پیاده کنیم.



حال هر تابعی که رابطه با 0 و 1 می‌توانیم با تبدیل کردن به فم SOP و با استفاده از AND، OR و NOT ساخته شده، شبکه مورد نیاز را می‌سازیم. به طور مثال اندیس از سه کپی رابطه مورد نظر رابطه $XY + \bar{Y}Z$ بسازیم، می‌توانیم آن را به صورت زیر نشان دهیم:



ب) اگر تابع XOR را 4 متغیر نشان دهیم توسط جدول کاردانو، جدول شیب شکل زیر می شود، هر یک این جدول ها می تواند

و هر خانه ای که 1 دارد باید یک خروجی در لایه مخفی دارد همان AND متغیرات آن است و در لایه آخر یک خروجی باید OR

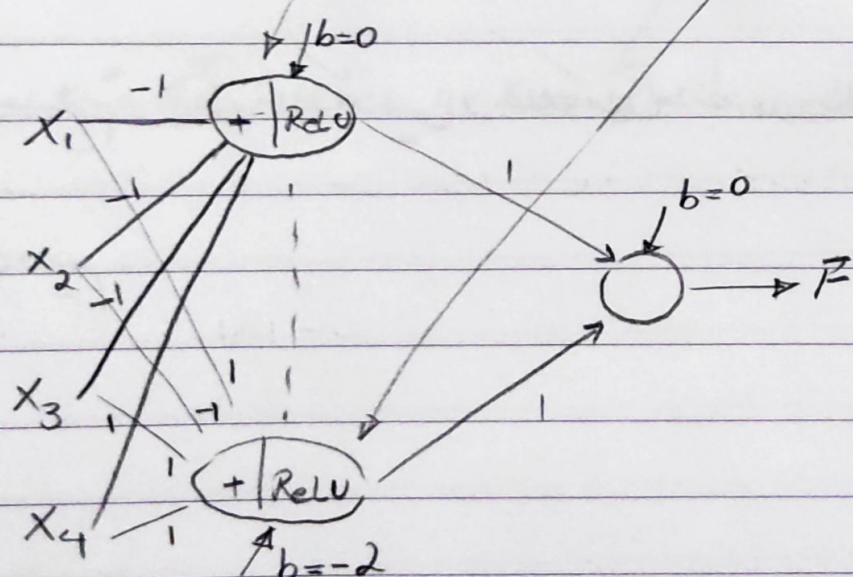
داریم. هر خانه که 0 است از 2 حالت مختلف ترکیب متغیرات این جدول می آید (4-1) 2 خانه مقدار 1 گرفته اند

و در لایه مخفی نیاز به خروجی داریم. این مسئله را می توانیم با یک لایه انیورت به جای هر N ورودی و 2^{N-1} خانه جدول کاردانو


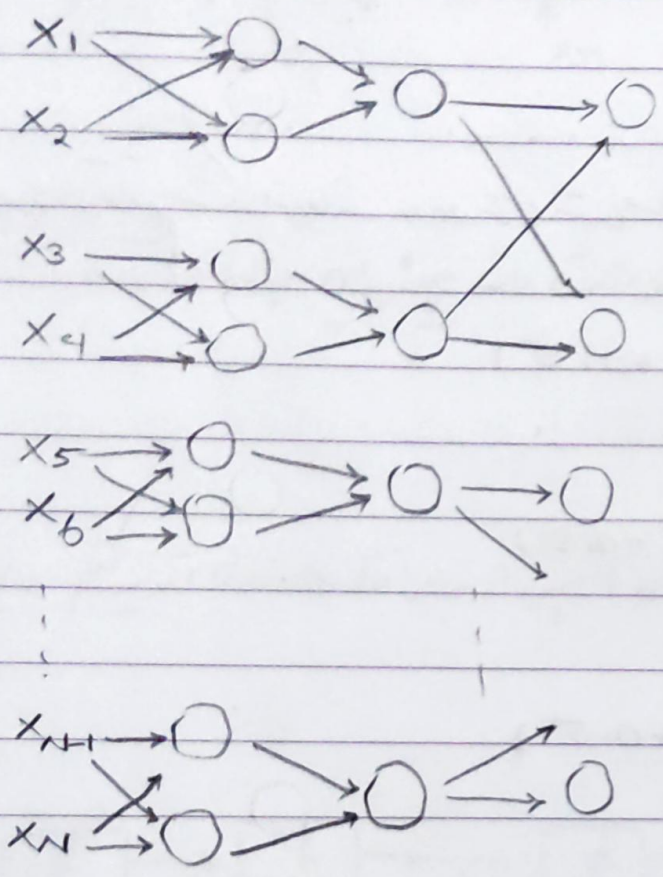
$X_3 X_4$ $X_1 X_2$	00	01	11	10
00	0	1	0	1
01	1	0	1	0
11	0	1	0	1
10	1	0	1	0

با براین لایه مخفی 2^{N-1} ، ورودی نیاز داریم.

$$F = \bar{X}_1 \bar{X}_2 \bar{X}_3 X_4 + \bar{X}_1 \bar{X}_2 X_3 \bar{X}_4 + \bar{X}_1 X_2 \bar{X}_3 \bar{X}_4 + \bar{X}_1 X_2 X_3 X_4 + X_1 \bar{X}_2 \bar{X}_3 X_4 + X_1 \bar{X}_2 X_3 \bar{X}_4 + X_1 X_2 \bar{X}_3 \bar{X}_4 + X_1 X_2 X_3 X_4$$



$$F = X_1 \oplus X_2 \oplus \dots \oplus X_N = (((X_1 \oplus X_2) \oplus (X_3 \oplus X_4)) \oplus ((X_5 \oplus X_6) \oplus (X_7 \oplus X_8))) \oplus \dots$$



* برای هر XOR، دو لایه نیاز داریم بنابراین N و 2 لایه خواهیم داشت و بی تعداد نورون ها به $3(N-1)$ کاهش می یابد که از رویه فعلی نسبت به تعداد نورون ها است.

Sigmoid .

$$\frac{1}{1 + e^{-2x}}$$

فرایه 11 مشتق پذیری است و در هر نقطه مشتق قابل حساب است.

12 این تابع monotonic است و نسبت احتمال هر دو را حفظ می کند.

13 گرایان smooth دارد و باعث می شود تغییرات ناگهانی نداشته باشیم.

14 مقدار خروجی آن بین 0 و 1 است بنابراین در مواقعی که نیاز داریم احتمال محاسبه کنیم، بسیار کارآمد است.

15 مقدار تابع در بازه های بالای 2 و پایین 2-، به ترتیب بسیار به 0 و 1 نزدیک می شود و به ما اجازه

تحقیق روشنی را می دهد.

معایب: 1 در نقاط ابتدایی و انتهایی این تابع مقدار گرایان بسیار کوچک می شود که باعث می شود، فرآیند یادگیری بسیار

کند شود و اگر مقدار گرایان صفر شود، یادگیری نخواهیم داشت و در چند عملی می بینیم. این مشکل vanishing gradient

نامیده می شود.

2 خروجی این تابع zero-centered نیست

3 از نظر محاسباتی سنگین است.

$$\frac{e^x - e^{-x}}{e^x + e^{-x}} \quad \tanh$$

فرای: این تابع از نظر سرعت بسیار سریع به تابع Sigmoid است. و به تفاوت هایی نیز دارد. یکی اینکه تعاد
خود را آن در بازه (۰-۱) است، zero centered است. تفاوت دیگر این است که برای بیان با شیب تندتری نسبت به
Sigmoid دارد و بنابراین گرایان می توانند تفاوت بیشتری بین دو خط و خطی با شیب سریع مناسب تر از Sigmoid است.

۱) این تابع هم Sigmoid دچار مشکل vanishing gradient می شود زیرا که نقاط انتهایی، گرایانی نزدیک
به صفر دارد.

۲) این تابع از نظر محاسباتی، آجی سنین است.

$$\text{ReLU} = \begin{cases} 0 & x \leq 0 \\ x & x > 0 \end{cases}$$

فرای: این تابع از نظر محاسباتی، بسیار سبک تر از ۲ تابع قبل است و به دلیل صفر بودن خودش به اندامی در درونش
باعث می شود که فعال سازی بسیار سبک تر شده و شیب سریع تر عمل کند. و به همین دلیل برای شبکه های خیلی بزرگ و شبکه های
۲) اگر می بینیم که در بازه مثبت و درون های تابع خطی ارائه شده و در ReLU یک تابع خطی نیست و یک خمیدگی

خوب است.

حساب: حساب یک تعاد در درون به صفر و تعاد به صفر نزدیک می شود، تعاد گرایان صفر شده و اگر شیب صفر نمی گیرد. ولی

مشکل vanishing gradient ندارد.

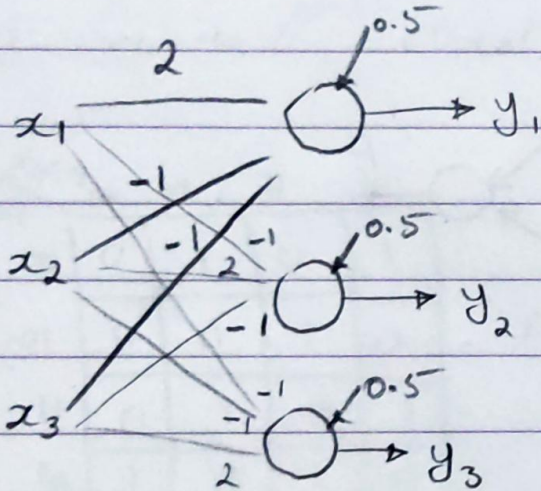
④ اگر ۳ عدد صحیح داشته باشیم می‌توانیم به طور مثال رابطه‌ای داشته باشیم که آن‌ها را بتوانیم:

اگر بدانیم:

$$\left. \begin{array}{l} a > b \\ a > c \end{array} \right\} \Rightarrow$$

$$a + a > b + c \Rightarrow 2a - b - c > 0 = 2a - b - c + 0.5 > 0.5 > 0$$

بنابراین می‌توانیم شبکه‌ای داشته باشیم برای شناسایی، تعداد شبکه‌های داریم:



$$y_1 = \text{relu}(2a - b - c + 0.5)$$

$$y_2 = \text{relu}(2b - a - c + 0.5)$$

$$y_3 = \text{relu}(2c - a - b + 0.5)$$

$$\text{weight decay} \Rightarrow w = (1 - \lambda)w - \alpha \Delta C_0$$

(V)

ΔC_0 در اینجا به معنی گرادیان تابع هزینه بدون regularization term است نسبت به وزن ها.

$$L_2 \text{ regularization} \Rightarrow C = C_0 + \frac{\lambda}{2} \|w\|_2^2$$

$$\frac{\partial C}{\partial w} = \frac{\partial C_0}{\partial w} + 2 \frac{\lambda w}{2} \Delta C = \frac{\partial C}{\partial w} \Rightarrow w = w - \alpha \Delta C = w - \alpha (\Delta C_0 + \lambda w)$$

$$\Rightarrow w = w - \alpha \Delta C_0 - \alpha \lambda w = (1 - \alpha \lambda)w - \alpha \Delta C_0$$

با کم کردن $\lambda \alpha$ از λ به رابطه اهمیت کردن وزن های بالا به صورت زیر می آید:

$$w = (1 - \lambda')w - \alpha \Delta C_0 \quad (\lambda' = \lambda \alpha) =$$

که این رابطه دقیقاً برابر با رابطه weight decay است. اثبات شد که SGD، L_2 Decay و weight Decay برابر

هستند و هر دو روش ها می توانند Adam این دو یکسان هستند.

Guided Backpropagation؟ این روش جزئیات اصلی تقویر را مشخص میکند. روش کار آن این است که فقط در

سوزن ها مانند detector کار میکنند که فیچر های خاصی از تقویر را شناسایی میکنند. بنابراین Guided Backpropagation
 قادر است گرایی را برابر صفر قرار دهد تا سیکسل های که در تقویر مهم هستند را هایلایت کند.

Guided Grad CAM: وابسته به این روش داریم به نام Class Activation Maps که محل مشخص کننده class

است و نقاط مهم مشخص کننده کلاس را مشخص می کند و فقط برای شبکه های کار می کند. دقیقاً قبل از prediction

از global average pooling استفاده می کنند. روش دیگری داریم به نام Grad CAM که مانند CAM،

Class discriminative است ولی سیکسل های مهم تقویر را نمایش نمی دهد و فرستادن نسبت به CAM این است که برای

شبکه ای قابل اتصال است؟ حال Guided Grad CAM و روش های Grad CAM و

Guided Back Prop. را با یکدیگر ترکیب کرده و هم بخش های مرتبط با کلاس را نشان می دهد و هم سیکسل های

مهم را در بین back propagation از لایه های ReLU هایلایت می کند.