


یادگیری ماشین برای سوانح تاریک - ترمین پنجم

نویسنده: کافور ۹۹۲۱۰۷۵۳

① الف) one-to-many: این شبکه‌ها تنها یک ورودی در هر زمان دارند و دنباله از خروجی را تولید می‌کنند:




هرگز نیاز به تمام کردن یک یا چند لایه بازگشتی نمی‌باشند. بلکه "یک" در ورودی به این معناست که

فقط یک ویژگی ورودی داریم. بلکه به این معناست که در هر Δt time step است یا اصلاً مستقل از زمان است.

کاربرد: عموماً به عنوان تولید کننده دنباله به کار می‌روند. مانند تولید یک موسیقی با گرفتن صوت آغازین یا ترجمه یا تولید غایبانه با ورودی کل شروع شده غایبانه.

many-to-one: این شبکه‌ها دنباله از ورودی با طول دلخواه می‌گیرند و سپس خروجی شایسته را تولید می‌کنند. یک خروجی تولید می‌کنند:




می‌توانند به شکل یک یا چند لایه بازگشتی متصل باشند

کاربرد: معمولاً برای دسته‌بندی داده‌های sequential

استفاده می‌شوند. مانند Sentiment Analysis که هر یک مستند یا خواننده و دسته‌بندی می‌شود به تعداد مثبت، منفی یا خنثی

است. یا می‌توان برای تشخیص کلمات موضوع اخبار از آن استفاده کرد.

many-to-many (syncd): در این مدل هر یک از ورودی‌ها می‌توانند خروجی داشته باشند.



علاوه بر مشخص است، هر خروجی برابر با ورودی خودش و تمامی خروجی‌ها


قبل از محاسبه می‌شود.

کاربرد: این از کارهای گسترده این مدل‌ها، پیش‌بینی‌های مرتبط در طول زمان است مانند پیش‌بینی میزان فروش هر روز یک فروشگاه

یا ارزش‌های سهام و کارهای دیگر آن مانند تشخیص گفتار real-time است.

many-to-many (unsyncd): بعضی مواقع می‌خواهیم که دنباله خروجی را پس از مدتی تا کارهای دیگری، تولید کنیم. در این

مدت‌ها می‌تواند مدل نیز استفاده می‌شود.



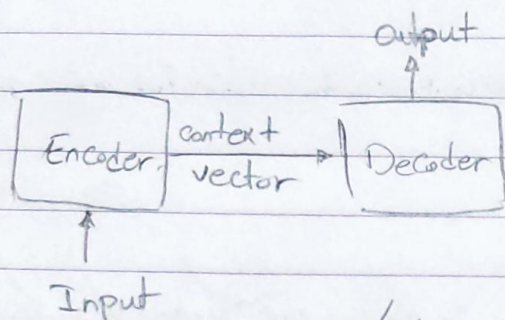
مکان‌های ورودی و خروجی می‌تواند متفاوت باشد.

کاربرد: در ترجمه ماشینی استفاده می‌شود به طور مثال ترجمه فارسی به انگلیسی، یا ترجمه فارسی خوانده شده و سپس ترجمه انگلیسی تولید می‌شود.

ب. مسئله Seq2Seq: نوع خاصی از مسائل Sequence Modelling هستند که ورودی، output، و دنباله Sequence هستند.

بنابراین در دسته many-to-many قرار می‌گیرند.

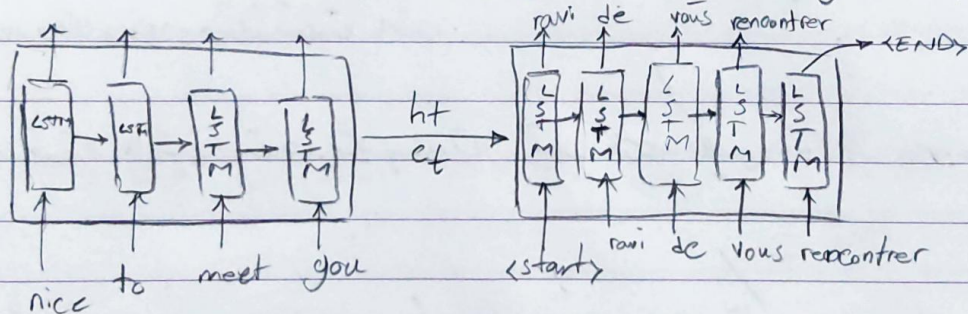
مدل encoder-decoder به صورت یک مدلی متشکل از دو بخش encoder و decoder است که به صورت یکدیگر پیوسته می باشد.



از جمله ماشین های متشکل از این دو بخش می توان به مدل های زیر اشاره کرد.

در این مقاله به طور خاص، بخش encoder، تمام لغات رشته ورودی را به یک vector تبدیل می کند و این vector را به بخش decoder می دهد. بخش decoder وظیفه دارد که جمله ترجمه شده را از لغات خروجی تولید کند.

اگر بخواهیم نگاه دقیق تری به داخل هر بخش داشته باشیم، در این مقاله از encoder و decoder به عنوان LSTM (Long Short-Term Memory) استفاده می کنیم.

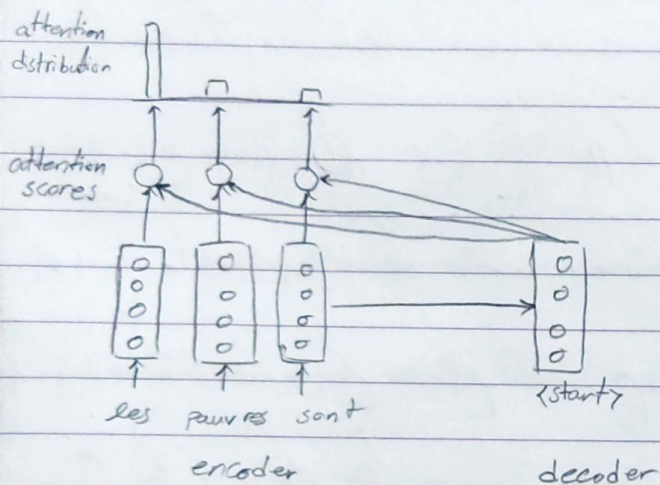


نکات قابل توجه این هستند که خودی های encoder، در حقیقت همان cell state، hidden state و context vector هستند. بخش decoder نیز با داشتن 'start' و 'context vector' شروع به تولید جمله خروجی می کند. هر وقت که LSTM مدلی به پایان می رسد، 'END' می تواند به عنوان 'END' استفاده شود.

چ: برای این بخش encoder، یک مدل تبدیل می‌دهیم که برای decoder سخت است که روی این مدل تمرین

لغات در جمله خروجیها متوجه شود. برای رفع این مشکل از یک attention استفاده می‌کنیم. decoder به attention

فرصت بخش‌های ورودی را می‌دهد و می‌تواند به راحتی در خروجی. و این کار باعث می‌شود که جملات ورودی و خروجی به هم



align شوند.

به عنوان مثال در یک جمله بیشترین امتیاز attention برای اولین کلمه است و

این باعث می‌شود که جمله خروجی با "then" آغاز شود.

۲) الف: برای این Back P.T. Time، نیاز است که در ابتدا شبکه را Roll Forward کنیم و مقادیر لایه‌های آن را به دست آوریم. حال

هر لایه زمانی یک خروجی دارد و تعداد لایه‌ها و بایاس‌ها بین لایه‌ها مشخص است. حال نیاز است که خروجی هر لایه را با خروجی مورد نظر

مقایسه کنیم، مقدار کدک را محاسبه کنیم و مقدار کدک‌های برابر با جمع مقادیر کدک‌های تمام لایه‌ها است. حال کفیف است

حالت BP. عددی، شروع به گزینش می‌کنیم و با استفاده از chain rule شروع به حرکت از سمت خروجی و لایه‌های پائین

به ورودی و لایه‌های اولیه می‌کنیم و مقدار وزن هر لایه را محاسبه می‌کنیم. تفاوت این روش با Back Propagation این است که

در اینجا هر لایه زمانی کدک‌ها را به هم می‌زنیم و به این فرآیند unfolding می‌گویند. در B.P. عددی و خروجی را

ب. exploding gradient vanishing gradient دو مشکل هستند باعث می شود یادگیری اجزا آشفته بماند و در طولی مقدار

گرایان خطی سریع صفر می شود و دیگر آنش خیلی کم داشت و در طولی مقدار گرایان بسیار بزرگ و NaN می شود و حالت ناپایداری ایجاد می شود.

رابطه های بارش می توان گرایان را بصورت لاگرانژین نوشت
$$\frac{\partial L}{\partial w} = \sum_{i=0}^T \frac{\partial h_i}{\partial w} \alpha \sum_{i=0}^T \left(\prod_{k=i}^T \frac{\partial h_k}{\partial h_{k-1}} \right) \frac{\partial h_k}{\partial w}$$
 در اینجا می بینیم

در حالت رخ برعکس: ① $\left\| \frac{\partial h_i}{\partial h_{i-1}} \right\|_2 < 1$ باعث vanishing gradient می شود و ② $\left\| \frac{\partial h_i}{\partial h_{i-1}} \right\|_2 > 1$

که باعث exploding gradient می شود، در حالت اول مقدار گرایان بصورت نمایی صفر می شود و باعث می شود که long period dependency ها را نتوانیم آموزش بدهیم و در حالت دوم مقدار گرایان به سمت بینهایت و NaN می رود و ناپایداری می شود

دلیل دیگری که این اتفاق در شبکه های بازگشتی رخ می دهد این است که شبکه ها ویدی می تواند بسیار بزرگ باشد و این به

معنای مقدار زیاد مشتق گیری ها است که باعث ایجاد مشکلات بالا می شود. با روش های مثل truncated BPTT و

gradient clipping می توان آن ها را رفع کرد.

پ.ا. می بینیم که معماری LSTM دارای سه بخش جاگواهای input gate، forget gate و update gate است که باعث

می شود cell state را با اطلاعات hidden state به لایه های بعدی برساند باعث می شود long term dependency را بهتر متوجه شود

حال می بینیم که در محاسبات هستند اندازه گرایان باعث تأثیر قرار می دهند یکی درون ها و دیگری توابع فعال سازی را با یکدیگر مقایسه

می کنند مشتق آن ها. حال اگر مقدار آن از این ها اندک تر شوند vanishing و اگر بزرگ تر شوند exploding اتفاق

می افتد. حال می بینیم در LSTM، تابع فعال سازی با مشتق آن است. بنابراین گرایان back propagate

به صفر و صفر نهایت می شود. نکته ثابت در ماندن وزن بیشتر بازگشت همان تابع فعل سازی forget gate است بنابراین

که این gate روشن باشد activation نزدیک ۱ باشد، گریه همان دچار vanishing نمی شود و به این دلیل که مقدار

فعل سازی forget gate از ۱ بیشتر نمی شود دچار exploding نمی شود. بنابراین معماری LSTM با درج مسئله

vanishing و exploding گریه همان به مانع می کند.

(۳)

مسئله exposure bias این است که همانطور که در صورت سوال آمده است در مرحله یادگیری teacher forcing

لازم و داده‌های تست را به عنوان ورودی به مدل زبانی می‌دهیم و این اتفاق باعث نابرابری بین train-test می‌شود

exposure bias نامیده می‌شود. این اتفاق می‌تواند منجر به overfitting شود و بنابراین مدل را generalize

کنیم. روش خاص از قبیل scheduled sampling برای مقابله با exposure bias توسعه داده شده‌اند. هنگامی که داده‌های

آفودش و تست توزیع نزدیک به هم نداشته باشند، عملکرد شبکه بسیار ضعیف خواهد شد.

به نظر می‌رسد اگر نخواهیم داده‌های صحنه را به فرامل عبوری بدهیم نتوانیم اصلاً مدل را آفودش دهیم و با این آفودش

زبان بسیار زیادی می‌برد. زیرا که داده‌های صحنه بخش از ورودی هر مرحله هستند.

(۴) هدف ما اینست - discriminator به دنبال تشخیص دادن $V(G, D)$ است. برای این کار generator به ما کمک می‌کند.

$$V(G, D) = E_{x \sim P_{data}} [\log D(x)] + E_{x \sim P_g} [\log (1 - D(x))]$$

$$= \int_x P_{data}(x) \log(D(x)) dx + \int_z P_g(z) \log(1 - D(g(z))) dz$$

$$= \int_x P_{data}(x) \log(D(x)) + P_g(x) \log(1 - D(x)) dx$$

برای هر $(a, b) \in \mathbb{R}^2 \setminus \{0, 0\}$ ، مقدار بیشینه تابع $y = a \log y + b \log(1 - y)$ در بازه $[0, 1]$ ، برابر با مقدار

$\frac{a}{a+b}$ حاصل می‌شود. بنابراین مقدار بیشینه برای discriminator برابر با $D_G^*(x) = \frac{P_{data}(x)}{P_{data}(x) + P_g(x)}$ خواهد بود.

$$C(G) = \max_D V(G, D) = E_{x \sim P_{data}} [\log D_G^*(x)] + E_{z \sim P_Z} [\log (1 - D_G^*(G(z)))]$$

$$= E_{x \sim P_{data}} [\log D_G^*(x)] + E_{x \sim P_g} [\log (1 - D_G^*(x))]$$

$$= E_{x \sim P_{data}} \left[\log \frac{P_{data}(x)}{P_{data}(x) + P_g(x)} \right] + E_{x \sim P_g} \left[\log \frac{P_g(x)}{P_{data}(x) + P_g(x)} \right]$$

در حقیقت اثبات کنیم که $C(G)$ همیشه منفی است نه الزاماً صفر است. $P_g = P_{data}$ ، پس آن برابر با $-\log 4$ خواهد بود.

$$P_g = P_{data} \rightarrow D_G^*(x) = \frac{1}{2} \Rightarrow C(G) = \log \frac{1}{2} + \log \frac{1}{2} = -\log 4$$

$$E_{x \sim P_{data}} [-\log 2] + E_{x \sim P_g} [-\log 2] = -\log 4$$

$$C(G) = -\log(4) + KL(P_{data} \parallel \frac{P_{data} + P_g}{2}) + KL(P_g \parallel \frac{P_{data} + P_g}{2}) \quad (KL = \text{Kullback-Leibler})$$

$$\Rightarrow C(G) = -\log 4 + 2 \cdot JSD(P_{data} \parallel P_g)$$

* این فاصله Jensen-Shannon بین دو توزیع قرار نامتناهی است و همیشه بین 0 تا 1 است. همان نام

که گفته اغلب برای $C(G)$ برابر با $-\log 4$ است. در حقیقت اتفاق می افتد که فاصله JS بین توزیع یکسان

آموزش و توزیع شبکه مولد یکسان و برابر صفر شود.

ج) همانطور که در بالا گفته شد، همیشه فاصله KL منفی است. $P_{data} \approx P_g$ (بیشتر) باشد. در این صورت

به نقطه بهینه برای تابع هدف برسیم.

(۵) معمولاً در حلقه‌های GAN مجموعه گسترده‌ای از خروجی‌ها تولید می‌کند و به طور متناوب در حلقه‌های آموزشی تصادفی به

چهره جدید تولید می‌کند. اما اگر generator یاد بگیرد که خروجی پذیرفته‌شده برای discriminator تولید کند، ممکن است به حلقه‌های

خودجانی راه‌اندازی کند. در واقع generator سعی می‌کند پذیرفته‌شده‌ترین خروجی برای discriminator پیدا کند. اگر generator

شرط کند به تولید کردن خروجی‌های (یا مجموعه‌های از خروجی‌ها)، بهترین کار برای discriminator این است که حلقه‌های آن خروجی

را رد کند. پس اگر discriminator در نسل بعدی نکته‌های بیشتری را رد کند و بهترین راه را پیدا کند. برای generator در iteration بعدی

بسیار ساده خواهد بود که پذیرفته‌شده‌ترین خروجی را برای discriminator پیدا کند. در هر چرخش generator،

تولید کننده، discriminator خاص آن چرخش، over-optimize می‌کند. و discriminator هیچ‌گاه یاد نمی‌گیرد که از نتایج

خارج شود. بنابراین generator حلقه‌های بین تعداد کمی خروجی می‌چرخد. که به این مشکل می‌گویند و گفته می‌شود.

(۶)

۱. وقتی که تابع هدف شبکه در صورت $\log(1 - D(x))$ باشد و در شروع یادگیری باشد، باقیمانده generator تقریباً

خوبی‌های تصادفی و هیچ معنی‌داری در discriminator به راحتی آن‌ها را شناسایی نمی‌کند. حال آنکه به توافق می‌آید که اگر این

برای generator بسیار کم و تقریباً صفر است. باعث می‌شود یادگیری بسیار کند شود که به آن saturation می‌گویند

ولی با استفاده از $\log(D(x))$ و ضرایب discriminator در ابتدا به راحتی شناسایی کند مقدار گرایان شبکه و در

زیاد است و سرعاً به سمت بهتر شدن حرکت می‌کند

(الف) در چنین شرایطی هر discriminator درست نیست پس به قدره این شرایط صفر خواهد بود:

$$\lim_{\|D-D^*\| \rightarrow \infty} \nabla_{\theta} E_{z \sim P_z} [\log(1 - D(g_{\theta}(z)))] = 0$$

$$\Rightarrow \nabla_{\theta} \log(1 - D(G(z))) = 0$$

ب) در این صورت گمان می‌کنیم که به شبکه مولد می‌تواند به راحتی با صفر است. مشکل vanishing gradient ایجاد می‌شود و جدا کردن نخواهیم داشت.

$$E_{z \sim P_z} [-\nabla_{\theta} \log D^*(g_{\theta}(z))] |_{\theta=\theta_0} = \nabla_{\theta} [KL(P_G \| P_r) - 2JSD(P_G \| P_r)] |_{\theta=\theta_0}$$

و بنابراین گمان می‌کنیم که در معکوس KL-divergence و JS-divergence مشکل شتابان به راحتی می‌تواند

شده مولد تفاوت واقعاً ترکیب شود اما ممکن است همیشه به سبب باشد.

(۷) اگر P_r و P_g دو توزیع اصلی داشته باشند در M manifold و P_r و P_g هر دو به صورتی

full dimension نباشند و فقط $\log 2$ را داشته باشند:

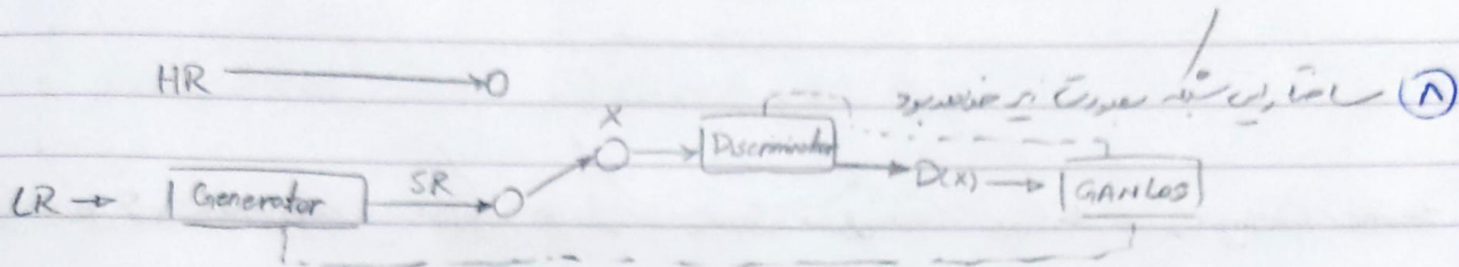
$$KL(P_r \| P_g) = +\infty$$

$$KL(P_g \| P_r) = +\infty$$


در چنین حالتی می‌توانیم که مقایسه divergence حتی در manifold ها به طور قاطعی به یکدیگر مرتبط باشند و به سبب می‌شوند.

ممکن است فرضی شبکه مولد خیلی خوب باشد ولی KL divergence به نهایت می‌رسد و در چنین شرایطی


فرآیند gradient descent استفاده از ویژگی‌های مقایسه‌ای ساختاری استفاده می‌شود. برای حل این مشکل می‌توانیم از ویژگی‌های مقایسه‌ای ساختاری استفاده کنیم.



Generator Network



Discriminator Network



HR
SR ?

generator loss function :
$$l^{SR} = \overbrace{l_x^{SR}}^{\text{Content loss}} + 10^{-3} \overbrace{l_{Gen}^{SR}}^{\text{adversarial loss}}$$

$$l_{Gen}^{SR} = \sum_{n=1}^N -\log D_{\theta_D}(G_{\theta_G}(I^{LR}))$$

$$l_x^{SR} = \text{MSE}(HR, SR)$$

discriminator loss function:

$$\min_{\theta_G} \max_{\theta_D} E_{I^{HR} \sim P_{\text{train}}(I^{HR})} [\log D_{\theta_D}(I^{HR})] + E_{I^{LR} \sim P_G(I^{LR})} [\log (1 - D_{\theta_D}(G_{\theta_G}(I^{LR})))]$$